

WSI

Ćwiczenie 1

Prowadzący : mgr inż. Mikołaj Markiewicz

Wykonał: Jan Kaniuka

Numer indeksu: 303762

Treść zadania – zagadnienie przeszukiwania i podstawowe podejście do niego.

Zaimplementować metodę gradientu prostego dla funkcji jednej zmiennej. Zbadać działanie metody w zależności od parametrów wejściowych:

- punkt startowy

- współczynnika uczenia / parametru kroku

Eksperymenty przeprowadzić dla funkcji z jednym minimum oraz dla funkcji z minimum lokalnym, czyli np. :

$$f(x) = x^2 + 3x + 8$$

$$f(x) = x^4 - 5x^2 - 3x$$

Nie trzeba implementować liczenia pochodnej z funkcji wejściowej - podajemy jako już znaną funkcję.

Przyjęte założenia oraz doprecyzowanie treści

W zadaniu nie zostało sprecyzowane *kryterium stopu* algorytmu. Typowe kryteria stopu dla metody gradientu prostego to: ograniczenie liczby iteracji, wartość gradientu bliska zero lub brak poprawy funkcji celu. W swojej implementacji zastosowałem ostatnie z wyżej wymienionych kryteriów:

Kryterium stopu : $|f(x_{k+1}) - f(x_k)| < e$

gdzie e – założona dokładność. Na potrzeby eksperymentów przyjąłem $e = 10^{-3}$

Raport z przeprowadzonych eksperymentów

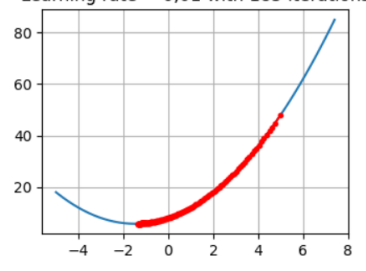
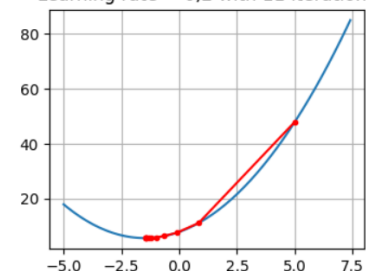
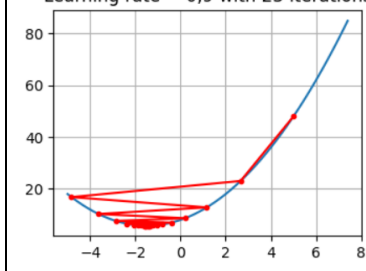
Funkcja kwadratowa z jednym minimum

Na początku zbadałem wpływ wartości *współczynnika uczenia* na wyznaczanie minimum.

Parametry eksperymentu: $f(x) = x^2 + 3x + 8$, $e = 10^{-3}$, punkt startowy $x = 5$

Przeprowadziłem kilka eksperymentów z różnymi parametrami algorytmu, lecz w sprawozdaniu zamieszczam jedynie te, które pozwalają na zaobserwowanie wpływu tychże parametrów na działanie *metody gradientu prostego*.

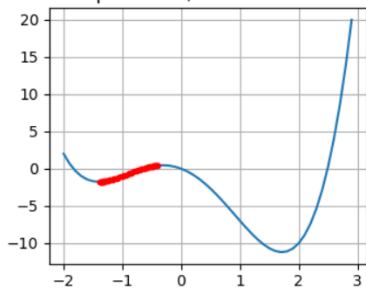
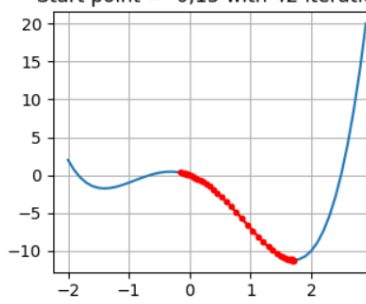
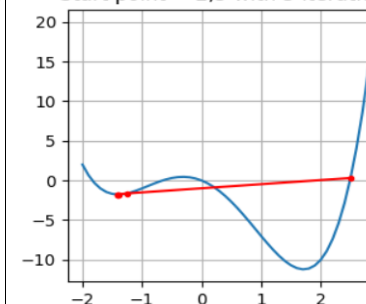
Pod każdym z wykresów zamieściłem wartość argumentu x , w którym funkcja osiąga minimum oraz związane obserwacje. Testowa funkcja kwadratowa osiąga swoje minimum dla $x = -1,5$.

<p>Learning rate = 0,01 with 185 iterations</p> 	<p>Learning rate = 0,2 with 11 iterations</p> 	<p>Learning rate = 0,9 with 23 iterations</p> 
$x = -1.35$	$x = -1,47$	$x = -1,53$
Bardzo mały parametr kroku skutkuje dużą liczbą iteracji. Schodzenie po tzw. „ <i>minus gradiencie</i> ” jest wyraźnie zbyt wolne i czasochłonne.	20-krotne zwiększenie długości kroku pozwoliło na znaczne ograniczenie liczby iteracji. Widać wyraźnie, że pierwsze <i>przesunięcie</i> do kolejnego punktu x_{i+1} jest największe, a w kolejnych krokach maleje.	Przyjęcie zbyt dużej wartości <i>learning rate</i> może skutkować oscylacjami. Kolejne kroki mają zbyt dużą wartość, co skutkuje <i>przeskakiwaniem</i> rozwiązania (<i>overshoot</i>). Takie zachowanie algorytmu jest wysoce niepożądane.

Funkcja stopnia czwartego z dwoma minimami lokalnymi

Druga funkcja (wielomian czwartego rzędu) ma dwa minima lokalne. Na jej przykładzie postanowiłem sprawdzić działanie metody w zależności od wyboru punktu startowego.

Parametry eksperymentu: $f(x) = x^4 - 5x^2 - 3x$, $e = 10^{-3}$, *learning rate* = 0,01

<p>Start point = -0,4 with 55 iterations</p> 	<p>Start point = -0,15 with 42 iterations</p> 	<p>Start point = 2,5 with 5 iterations</p> 
W pierwszym przypadku jako punkt startowy wybrano $x = -0,4$. Algorytm zaczynając z tego miejsca znalazł minimum – niestety jedynie lokalne. Niewielkie przesunięcie punktu początkowego w prawo (do $x = -0,15$) poskutkowało znalezieniem minimum globalnego. Wniosek: należy być ostrożnym podczas wybierania punktu startowego w okolicach maksimum lokalnego.		W tym przypadku zwiększyłem <i>learning rate</i> do wartości 0,1. Chciałem przez to pokazać, że mimo rozpoczęcia procedury obok <u>minimum globalnego</u> , możemy <i>przeskoczyć</i> do <u>minimum lokalnego</u> przez zbyt dużą wartość kroku.

Wnioski i przemyślenia

- Dobranie zbyt dużej wartości *learning rate* skutkuje na ogół oscylacjami i *przeskakiwaniem* minimum.
- Dobór punktu startowego jest kluczowy dla funkcji z wieloma minimami lokalnymi. Aby częściowo rozwiązać ten problem można uruchomić algorytm kilkakrotnie dla różnych (randomowych) punktów startowych.