

WSI

Ćwiczenie 2

Prowadzący : mgr inż. Mikołaj Markiewicz

Wykonał: Jan Kaniuka

Numer indeksu: 303762

Treść zadania – algorytmy ewolucyjne i genetyczne

Zaimplementować algorytm ewolucyjny dla problemu minimalizacji funkcji n-zmiennych np. dwuwymiarowe: (Można zacząć od implementacji dla wektora jedno-elementowego, funkcji x^2). Przykłady funkcji do sprawdzenia: *Rosenbrock Function*, *Shubert Function*, *Bird Function*.


Wykorzystać selekcję turniejową, sukcesję elitarną i mutację gaussowską $x \pm \sigma \cdot N(0, 1)$.

Kryterium stopu: wystarczy na liczbę iteracji, ale można dodać inne.

Do krzyżowania użyć pełnej rekombinacji arytmetycznej.

Raport z przeprowadzonych eksperymentów

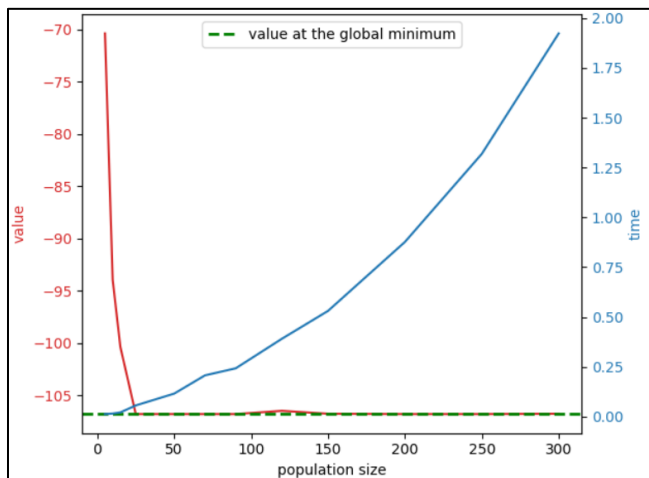
Zależność wartości funkcji celu od liczby iteracji dla różnych parametrów (Bird Function):



Eksperyment przeprowadzono dla 500 iteracji, lecz stabilizację zaobserwowano już po około 300. Populacja inicjalna z osobnikami „klonami” o małym rozmiarze i współczynniku sigma potrzebuje większej liczby iteracji niż populacja o osobnikach losowych. Losowa populacja (najlepiej też liczna) zapewnia nam dobre próbkowanie całej przestrzeni oraz globalny charakter poszukiwań. Porównując krzywe **pomarańczową** oraz

niebieską widać, że większa siła mutacji zmniejsza nacisk selektywny i minimum znajduwane jest wyraźnie szybciej. Wpływ rozmiaru elity widzimy na przykładzie krzywych **zielonej** i **czerwonej** – najlepsze osobniki przechodzą do kolejnej generacji populacji i wymuszają eksploatację (poprzedzoną przez dokładną eksplorację spowodowaną losowością oraz dużą liczebnością osobników populacji inicjalnej). Duża różnorodność populacji inicjalnej jest wysoce pożądana, gdyż i tak ulega ona zmniejszeniu w toku optymalizacji.

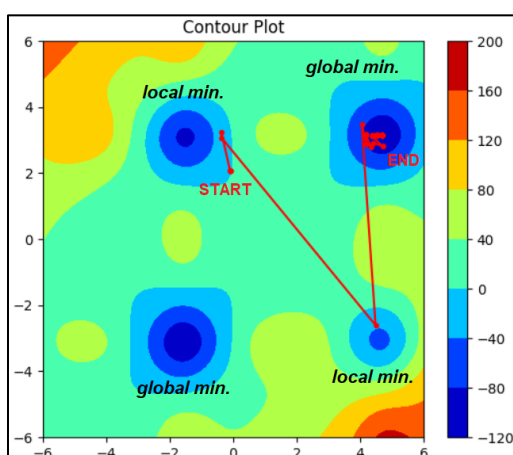
Zależność czasu/wyniku działania algorytmu od liczności populacji:



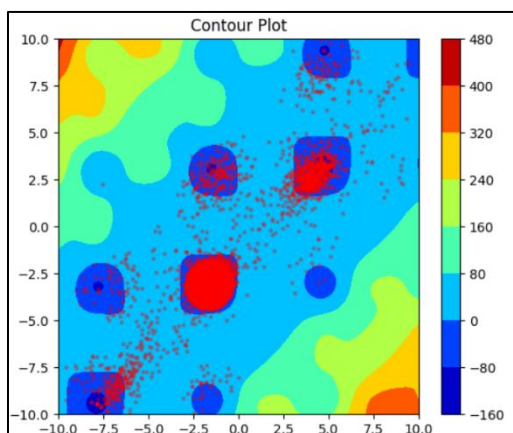
Wykres obok dowodzi, że zwiększanie liczności populacji prowadzi do poprawy wartości rozwiązania przy jednoczesnym wzroście nakładu obliczeń. W tej sytuacji należy znaleźć kompromis. Można zaobserwować, że od populacji liczącej około 40 osobników rozwiązanie jest bliskie wartości minimum globalnego (zielona, przerywana linia). Jeżeli dopuszczamy pewien błąd i nie dysponujemy zasobami pozwalającymi dowolnie zwiększać licznosc populacji, to

wtedy takie rozwiązanie możemy uznać za zadowalające. (Punkty z wykresu to średnie dla 3 kolejnych wywołań algorytmu przy 100 iteracjach dla *Bird Function*)

Najciekawsze przypadki pozyskane podczas eksperymentów



Na wykresie konturowym dla *Bird Function* zazaczyłem na **czerwono** i połączyłem ze sobą punkty odpowiadające kolejnym aproksymacjom minimum globalnego. Wymusiłem inicjalizację niewielkiej populacji „klonów” (15 osobników) w okolicy punktu (0,0) z $\sigma = 3$ dla 500 iteracji. Duża siła mutacji zapewniła dobre zdolności eksploracyjne, co pozwoliło znaleźć optimum globalne, mimo początkowego przechodzenia przez optima lokalne.



Drugi wykres pokazuje całe pokolenia populacji w kolejnych iteracjach (jasność punktów odpowiada upływowi czasu). Eksperyment wykonano dla bardzo licznej, „randomowej” populacji (500 osobników), rozmiaru elity = 5, rozmiaru turnieju = 10, oraz prawdopodobieństwa mutacji = $\sigma = 0.5$. Widać wyraźnie bardzo dobre pokrycie całej przestrzeni poszukiwań spowodowane różnorodnością osobników populacji inicjalnej.

Wnioski, przemyślenia i obserwacje: Rozsądne wydaje się ustawienie dużej siły mutacji na początku, aby wymusić silną eksplorację, a potem zmniejszenie siły mutacji na pewnym etapie działania algorytmu w celu poprawy eksploatacji i uzyskania dokładniejszego rozwiązania.